

研发资本化风险排序 与问询函可行性测试

基于 150 份年报 PDF 的结构化抽取与风险评分

数据挖掘与机器学习 · 课程项目二 · 2026 年 6 月

金融问题：哪些研发资本化特征与交易所问询相关？

子问题 1

高资本化率是否更容易
与问询相关？

行业偏离度

子问题 2

资本化率的剧烈变化
是否更容易与问询相关？

跨期变化

子问题 3

资本化条件描述模糊
是否更容易与问询相关？

文本模糊度

定位：风险排序，不是违规判定。输出的是「复核清单」，不是「黑名单」。

数据来源与规模

- 数据来源：巨潮资讯网 (www.cninfo.com.cn) 公开公告，深证信官方 API (OAuth2 认证)
- 50 家公司 × 3 年 (2021-2023) = 150 份年报 PDF，三大行业覆盖
- 医药制造 20 家 + 电子设备 20 家 + 软件信息 10 家
- 150 个唯一 SHA256, collision = 0 —— 数据去重完整
- 难度档位：● 挑战档 (≥50 份 PDF、≥10 字段、多公告类型、闭环分析)

Schema 设计：观察单位与核心字段

观察单位

company-year (公司 × 年报年度)

设计原则

不训练 ML 模型

全部使用可解释的金融规则


每个关键字段带 evidence_text + page_no

字段	类型
capitalization_rate	核心自变量
industry_percentile	核心自变量
change_zscore	核心自变量
fuzziness_score	核心自变量
capitalization_related	因变量（问询标签）
evidence_text	证据字段

MinerU 解析与 Section 路由

- MinerU API batch: 150 份 PDF → Markdown, 275 个 page segment 全部 success
- 超过 200 页的年报自动分段提交, 保留 HTML 表格结构
- Section 路由: 5 条规则 (研发费用 / 开发支出 / 无形资产 / 资本化政策 / 收入确认)
- 关键词匹配 + 正负向打分, 输出 750 行真实 corpus 数据
- 输出: outputs/reports/section_check_report.csv (完整可审计)

Workflow: 13 阶段 Pipeline



确定性表格提取 + LLM 抽取双路线



Pydantic 校验 + 会计恒等式 (5% 阈值)



CLI 一键调度: `uv run python src/main.py --from-stage validate --to-stage report`



测试覆盖: 51 个 pytest 用例

风险评分模型：四维信号聚合

行业偏离度 Industry Score

权重 0.25

资本化率在同行业同年度的
百分位 $\times 100$

跨期变化 Change Score

权重 0.25

仅取正向跳升（资本化率
突然上升）， $Z\text{-score}/2 \times 100$

条件模糊度 Fuzziness Score

权重 0.25

会计估计模糊词命中数 /
(文本长度/200) $\times 100$

恒等式置信度乘数 I：金额关系越一致，置信度越高；不一致时打折扣而非加信号

$$RS = \Sigma(w_i \cdot S_i) / \Sigma w_i \times I \quad \text{默认 } w \text{ 各 } 0.25, \text{ 等权即 } (IS+CS+FC)/3$$

当前结果：关键数字

150

年报 PDF

全部通过 validate

83 / 67

有风险分 / 未评分

no-score 默认非异常

11.57%

资本化率均值

中位数 2.67% (n=60)

17

异常条数

industry_outlier 16 + change_spike 1

维度	分组	资本化率均值
行业	医药制造	15.26%
行业	电子设备	7.62%
行业	软件信息	19.09%
年度	2021	11.45%
年度	2022	18.03%
年度	2023	5.47%
异常组 vs 非异常	23.81% vs 6.73%	

Demo 证据链：中兴通讯 2021 年报

PDF 年报 → MinerU Markdown → Section 定位 → LLM 抽取 → 校验 → 最终结果

项目	金额（万元）	evidence_text（原文片段）
研发投入总额	1,880,400	「研发投入金额 18,804.0」
资本化金额	180,650	「资本化的金额 1,806.5」
费用化金额	1,699,750	「费用化的金额 16,997.5」
资本化率	9.61%	「资本化研发投入占研发投入的比例 9.61%」

会计恒等式： $180,650 + 1,699,750 = 1,880,400$ ✓ 差异 < 0.01%

最终结果： **风险分 35.715 · 非异常 · TN**

闭环矩阵与 TN 水分：诚实呈现结果

混淆矩阵		
	预测异常	预测非异常
实际异常	TP = 0	FN = 1
实际非异常	FP = 17	TN = 132

Precision = 0.0

Recall = 0.0

Top-K Precision = 0.0

TN 水分 ⚠

TN = 132 中 67 条缺数据未评分

默认归非异常

→ TN 被高估

唯一 FN：汇顶科技 2022

收到研发资本化相关监管工作函

但资本化率字段缺失，风险分=0.0

→ 问题出在输入覆盖，不是评分逻辑

三个 Baseline 对比 (precision 全部 ≈ 0)

Baseline	预测数	TP	FP	FN	Precision
规则评分	17	0	17	1	0.0
cap_rate top20%	12	0	12	1	0.0
全标正	150	1	149	0	0.0067

失败案例与评估局限

评分模型局限

行业百分位不分方向（0% 资本化率也得满分）

参数全部启发式、未校准

抽取质量（35 条人工评估）

准确率 46.4%

section_error 27 / data_error 20 /

hallucination 8

评估 agent 与 extractor 同源 LLM——共错风险

问询标签

MVP 版本（关键词剪枝 + LLM 语义初筛）

正样本仅 1 条，统计上无法评估

其他：page_no 缺失、跨期变化仅覆盖两年

每个局限都有对应的改进方向——详见报告 §13

Vibe Coding 反思: AI 帮了什么、错在哪、如何验证

✅ AI 帮了什么

- 全流程 13 阶段代码生成
- MinerU 环境 bug 逐层诊断
- 方法论审计 (fuzziness 词表去毒、
- change_zscore 方向修正、industry 显式化)

❌ AI 在哪里出错

- fuzziness 词表含「等/相关/未来」(未看数据就设词表)
- change_zscore 用 abs() (没区分上升/下降的经济含义)
- 行业靠顺序推断 (文档声称申万一级, 代码实际靠猜)
- 文档 overclaim (「异常检测」「闭环验证」→ 改为「风险排序」「可行性测试」)

如何验证: 硬数字强制溯源 loop_evaluation.json + 51 个 pytest + mini pipeline + 35 条人工抽查

8 个已知局限与下一步

1. 正样本太少 (1/150)

2. TN 含水 (67/132 条未评分默认非异常)

3. 问询标签 MVP 版本

4. page_no 缺失

5. 抽取准确率 46.4%

6. 参数全部启发式

7. 评估 agent 与 extractor 同源 LLM

8. 行业百分位不分方向

如果有更多时间 → 扩大公司池 · 全文语义标签 · 参数敏感性分析 · 抽取质量提升

答辩问题预案

Q1

Q1: TP=0, 这项目还有什么意义?

方法链路已可工作, 正样本少是数据特征而非方法失败。诚实呈现「信号不足」本身就是科学结论。

Q2

Q2: 为什么不用 ML 模型?

课程明确「不训练大模型」; 规则评分可解释, 每个维度的金融含义清晰, 适合审计师/分析师场景。

Q3

Q3: 问询标签怎么做的?

当前是 MVP (关键词剪枝+LLM 初筛)。全文语义标签是下一步, 受限於时间和 API 成本。

Q4

Q4: 人工评估 46.4% 的准确率能接受吗?

不能接受作为最终产品, 但能接受作为 MVP。诚实标注了同源 LLM 共错风险, 主要错误类型已定位。

Q5

Q5: 资本化率 0% 为什么风险分满分?

行业百分位的设计 bug——只度量偏离度不区分方向。已在局限中如实说明。

Q6

Q6: 50 家公司怎么选的?

申万一级分类 (医药制造/电子设备/软件信息), crawl.yaml 显式配置。覆盖研发密集型行业。